

UMBP Tier Management 成本与性能实验报告

DeepSeek-V4-Pro • 8×MI355X • 三组 900 秒正式 E2E

验证在 LLM 推理场景下，以 SSD 替代部分 DRAM 后的成本、容量与性能变化，并确认 multi-page SSD staging 与 BUSY/retry 修复在真实负载下稳定工作。

3 / 3

正式实验成功完成

0

请求错误、BUSY 超时、slot-full

+13.5%

128D+640S 相对基线完成请求

实验日期：2026-08-26

报告版本：完整中文版 • 2026-08-27

成本模型：DRAM:SSD = 5:1 / GiB

1. 执行摘要

核心结论

三组正式实验均以 0 请求错误完成。等容量的 128D+128S 以约 15–20% 性能损失换取 40% 模拟成本节省；等模拟成本的 128D+640S 提供 3× 总容量，在本次 fixed-duration closed-loop replay 中超过 256D 基线。

配置	定位	总容量	成本	请求	TTFT p50
256D	全 DRAM 基线	256 GiB	100%	637	21.441 s
128D+128S	等容量、降成本	256 GiB	60%	534	25.612 s
128D+640S	等成本、扩容量	768 GiB	100%	723	16.834 s

主要发现

128D+128S 相比 256D

- 模拟成本降低 40%
- 完成请求数下降 16.2%
- TTFT p50 增加 19.5%
- 900 秒平均输入吞吐下降 17.9%

128D+640S 相比 256D

- 模拟成本相同，总容量扩大到 3×
- 完成请求数增加 13.5%
- TTFT p50 降低 21.5%
- 900 秒平均输入吞吐增加 17.3%

正确性结论

- 两个混合组均真实触发 DRAM → SSD offload、SSD read 和 SSD → DRAM promotion。
- 两个混合组均未出现 layer-wise load 失败、BUSY retry 超时或 staging slot-full。
- 128D+640S 的优势来自更大的缓存容量，不表示 SSD 本身比 DRAM 快。

2. 容量作用域与部署拓扑

报告中的 128/256 GiB DRAM 和 128/640 GiB SSD 均为整台节点 total，绝非 per GPU。
8 个 GPU/DP workers 共享同一个 UMBP pool，这些容量不能再乘以 8。

配置	节点总 DRAM	节点总 SSD	是否 per GPU
256D	256 GiB	无	否
128D+128S	128 GiB	128 GiB	否
128D+640S	128 GiB	640 GiB	否

SSD staging 8 GiB 和 ranged scratch 512 MiB 也都是 standalone 进程级总量，不是每 GPU 分别配置。

UMBP 模式：standalone + 独立 Master



组件	部署方式	作用
SGLang	8 个 GPU/DP workers	通过 Unix domain socket 访问共享 UMBP
UMBP standalone	独立于 SGLang 的单独进程，与 GPU 同节点	承载 PoolClient、PeerPool、DRAM/SSD backend 和 KV 数据面
UMBP Master	独立进程；控制端口 59151，metrics 59152	元数据、注册、心跳、路由、tier 控制面和指标汇总
KV 数据路径	本节点 local backend	KV bytes 在 standalone 与本地 DRAM/SSD 间移动， 不经过 Master

SGLang 连接形式：`unix:///run/umbp/standalone/*.grpc.sock`。standalone 内部的 DistributedClient 再向 Master 注册并上报容量、命中和迁移指标。

3. 硬件、版本与成本模型

硬件与存储

- GPU：8 × AMD MI355X。
- 三组原始正式实验均运行在同一台 n09-25 节点。
- SSD tier 使用该节点一块 3.5 TB NVMe SSD。
- SSD backend 位于 /dev/nvme0n1p2 的 ext4 根文件系统。
- 该 SSD 同时承载系统根文件系统，不是独占 benchmark 盘。

镜像与修复版本

配置	MORI 镜像	说明
256D	...-20260826-75c50dc4	全 DRAM 原始基线
128D+128S	...-c68b4090-busyretry	multi-page staging + BUSY/retry
128D+640S	...-c68b4090-busyretry	multi-page staging + BUSY/retry

`c68b4090` multi-page SSD staging `3673fee7` BUSY/retry 正式提交

客户端镜像：rocm/pytorch-private:sglang-0.5.14-rocm720-mi35x-20260702-agentx-client-20260703-111826
AIPerf checkout：dc975aaa；修复已推送至 origin/feat/umbp-multi-backend。

成本模型

假设：1 GiB DRAM = 5 × 1 GiB SSD

256D

= 256 × 5

= 1280

→ 100%

128D + 128S

= 128 × 5 + 128

= 768

→ 60%

128D + 640S

= 128 × 5 + 640

= 1280

→ 100%

DRAM:SSD = 5:1 是本实验的成本模型，不是实际采购报价。报告中的“等成本”仅指该模型下成本相同。

4. UMBP backend 与 Tier policy

通用 UMBP 参数

参数	值	作用域/说明
UMBp page size	64 KiB	三组一致
ranged scratch	512 MiB	standalone 进程总量
DRAM read lease	500 ms	保护读取页
remote fetch cache	开启	三组一致
hugepages	实际关闭	三组 policy 创建 backend 时均为 false

旧基线启动日志中的 `hugepages=true` 是启动输入；policy 实际创建 DRAM backend 时 `use_hugepages=false`。

混合组 SSD 参数

参数	值	说明
SSD page size	64 KiB	与 UMBp page 一致
staging slots	131,072	支持 multi-page object
staging arena	8 GiB	standalone 总量
SSD read lease	500 ms	保护 staged read pages
resolve BUSY timeout	30 s	有界整批重试
single-flight SSD read	开启	合并重复 SSD 读取

128D+128S: `/tier_cost_ssd/equal_capacity`

128D+640S: `/tier_cost_ssd/equal_cost`

混合组 Tier policy

参数	值	含义
entry_tier	hot	新数据先写 DRAM
hot / cold backend	DRAM / SSD	hot 仅 DRAM，cold 仅 SSD
offload_trigger	watermark	由 DRAM 使用率触发 offload
high / low watermark	0.90 / 0.70	90% 开始，offload 到 70% 停止
offload_to	cold	DRAM → SSD
promote_trigger	on_hits = 2	SSD 对象命中两次后提升
promote_mode	copy	提升到 DRAM，同时保留 SSD 副本

5. 模型、调度与 Workload

SGLang 模型参数

模型 / context	DeepSeek-V4-Pro / 262,144 tokens
并行	TP=8, DP=8, EP=8; DP attention、DP LM head 开启
MoE / attention	A2A backend=mori; dense TP=1; attention backend=dsv4
KV cache	dtype=fp8_e4m3; SGLang KV page=256 tokens
显存比例	mem_fraction_static=0.65
并发	CLI max_running_requests=256; 每个 DP worker 有效值=32
SWA / connector	full-token ratio=0.1; MORI unified tree connector
数据与布局	layer_wise; write_through; page_first
其他	shared-experts fusion 关闭; pre-warm NCCL、metrics/cache report 开启

max total tokens 与 prefill

实验未显式设置 `--max-total-tokens`，即 `max_total_tokens=None`。

配置	每 DP worker max_total	8 DP 合计	有效 chunk	max prefill
256D	4,091,904	约 32.74M	1,024	16,384
128D+128S	4,089,344	约 32.71M	1,024	16,384
128D+640S	4,089,344	约 32.71M	1,024	16,384

启动脚本请求 `chunked prefill=8,192`，SGLang 运行时有效值为 1,024。max_total 是并发驻留 device KV 容量，不是 900 秒累计 token 上限。

Workload 固定参数

Driver / trace	AIPerf AgentX v0.3 closed-loop replay / semianalysis_cc_traces_weka_with_subagents_256k
轨迹 / seed	393 trajectories / seed 42 / 起点范围 25%–75%
负载	CONC=16; 16 lanes; profiling=900 s; slice=1.0 s
输出 / context	OSL 强制 1 token; 最大 context/ISL=262,144
失败阈值	10%

6. Trace 一致性与输入长度

三组的 16 个 lane 使用完全相同的 trace ID 和初始采样位置。因此请求数差异不是随机抽取不同 trace，而是更快的配置在相同 900 秒内推进得更远。

```
lane 00 (三组完全一致)
sample_time=53%  root_next=46/61
trace_id=002001296e8a8c38ad9d7cc436d691afc602
```

实际 Input Sequence Length 分布

配置	Mean	p50	p75	p90	p95
256D	94,572	85,414	129,183	183,906	205,946
128D+128S	92,651	87,589	123,656	178,769	202,988
128D+640S	97,713	86,931	134,960	185,700	207,302

三组 ISL 分布接近；128D+640S 的平均输入长度反而略高于基线，因而其性能优势不能用“输入更短”解释。

实验可比性检查

检查项	结果
GPU 节点	三组原始正式运行均为 n09-25
模型与并行	一致：DeepSeek-V4-Pro，TP/DP/EP=8/8/8
trace / seed / lanes	一致：393 trajectories，seed 42，16 lanes
运行时长 / 并发	一致：900 秒，CONC=16
device KV tokens	基本一致：每 DP 约 4.09M
MORI 镜像	不一致：基线旧镜像，混合组修复镜像

7. 性能结果

完成请求与 TTFT

配置	成功	错误	p50	p75	p95	p99
256D	637	0	21.441 s	48.648 s	164.580 s	636.158 s
128D+128S	534	0	25.612 s	60.288 s	188.638 s	649.788 s
128D+640S	723	0	16.834 s	38.647 s	106.016 s	180.251 s

输入吞吐

配置	总输入 tokens	平均 req/s	平均 input tok/s	末段 server tok/s
256D	60.243M	0.708	66.9k	61.086k
128D+128S	49.476M	0.593	55.0k	49.618k
128D+640S	70.647M	0.803	78.5k	72.743k

完整 900 秒平均吞吐比单个末段采样点更适合作为总体性能指标。

相对 256D 基线变化

指标	128D+128S	128D+640S
完成请求数	-16.2%	+13.5%
TTFT p50	+19.5%（更慢）	-21.5%（更快）
TTFT p75	+23.9%	-20.6%
TTFT p95	+14.6%	-35.6%
TTFT p99	+2.1%	-71.7%
平均 input tokens/s	-17.9%	+17.3%

8. KV cache 与 UMBP 命中

配置	Trace 理论 prefix hit	Server KV prefix hit	DRAM hot hits	SSD cold hits
256D	95.0%	92.8%	2,163,144	0
128D+128S	95.1%	92.9%	1,863,947	73,525
128D+640S	95.1%	91.1%	2,370,533	105,427

这两类指标不能混为一谈。
“Server KV prefix hit rate” 是 SGLang 服务端 prefix cache 指标； UMBP hot/cold hits 是服务启动以来的累计 read-hit counter，包含 warmup。

为什么不报告 UMBP 真正 hit rate

- 当前 metrics 缺少匹配的总 resolve attempts/miss 分母。
- 累计 counter 包含 warmup，不仅是 900 秒 profiling window。
- fixed-duration closed-loop 下，各组完成请求数和推进距离不同。
- 因此不能将累计 hot/cold hits 直接除以完成请求数解释为命中率。

合理解读

- 混合组 cold hits 非零，证明 SSD tier 确实被读取。
- 128D+640S cold hits 更高，与完成更多请求、保留更多 cold KV 同时发生。
- 要做严格比较，应在 profiling 前后采集 counter delta，并补充 resolve 分母。

9. 最终容量占用

Prometheus metrics 使用十进制 GB：128 GiB=137.44 GB，256 GiB=274.88 GB，640 GiB=687.19 GB。

配置	DRAM used / total	DRAM	SSD used / total	SSD	总占用
256D	272.98 / 274.88 GB	99.3%	不适用	—	99.3%
128D+128S	135.83 / 137.44 GB	98.8%	117.55 / 137.44 GB	85.5%	92.2%
128D+640S	137.43 / 137.44 GB	≈100%	184.41 / 687.19 GB	26.8%	39.0%

SSD 占用直观比较



128D+128S

DRAM 与 SSD 均处于较高占用，SSD 仅剩约 19.89 GB，并发生明显 eviction。

128D+640S

DRAM 已满，但 SSD 尚余约 502.78 GB，容量压力显著更低。

“184.41 / 687.19 GB” 含义：128D+640S 组的 SSD backend 最终实际使用 184.41 GB，逻辑总容量为 687.19 GB（即 640 GiB），占用率 26.8%；不是两块盘或 per-GPU 容量。

10. Tier transition 与 SSD 数据面

Tier Management 行为

配置	Offload	Promotion	Eviction freed	Attempted	Succeeded
256D	0	0	0	0	0
128D+128S	144.486 GB	4.591 GB	28.417 GB	60,558	60,557
128D+640S	160.630 GB	5.675 GB	1.671 GB	72,386	72,385

两个混合组 attempted 均比 succeeded 多 1：最终 scrape 时仍有一次 transition 在途；未观察到 failed outcome。

SSD 数据面指标

配置	Read bytes	Copy bytes	Read OK	Lead	Coalesced	Victims
128D+128S	153.669 GB	145.712 GB	70,025	9,468	60,557	9,240
128D+640S	175.167 GB	185.744 GB	86,017	13,632	72,385	3,417

- Single-flight lead：实际发起 SSD 读取的 leader。
- Coalesced duplicate：被 single-flight 合并的重复 SSD 读取。
- Read OK = lead + coalesced duplicate。
- 这些也是服务完整生命周期累计 counter，包含 warmup。

容量压力差异

128D+128S 释放 28.417 GB SSD 数据、产生 9,240 个 eviction victims；128D+640S 仅释放 1.671 GB、产生 3,417 个 victims。更大的 SSD tier 显著降低容量淘汰压力。

11. 稳定性、Bug 修复与日志证据

指标	256D	128D+128S	128D+640S
benchmark 请求错误	0	0	0
layer-wise load failures	0	0	0
BUSY retry timeout	不适用	0	0
SSD staging slot-full	不适用	0	0

本次修复验证

- 1. **Multi-page staging:** SSD backend 支持大于 64 KiB 的对象，使用多 staging pages，并通过原子预留与 rollback 保证失败安全。
- 2. **BUSY 语义:** 暂时 staging 压力返回 BUSY，而不是误报永久 MISSING。
- 3. **有界批量重试:** PoolClient 对整批 resolve 进行 bounded backoff，避免并发读取产生 false miss。

关键日志摘录

```
256D DRAM:
[PageBackend] Init ... total_bytes=274877906944
[DistributedClient] medium=[DRAM pool=262144MB ...] page_size=64KB

128D+640S:
[PageBackend] ... total_bytes=137438953472
[PeerSsdManager] SSDTier ready ... capacity=687194767360B
[SsdBackend] Init staging_pages=131072 page_size=65536
arena_bytes=8589934592

Benchmark:
256D      Total requests: 637 | TTFT median 21441ms
128D+128S Total requests: 534 | TTFT median 25612ms
128D+640S Total requests: 723 | TTFT median 16834ms

Hybrid error scan:
layerwise_failures=0 busy_timeouts=0
ssd_staging_slot_full_rejects=0
```

12. 结果解释、限制与后续验证

128D+128S：等容量降成本

与基线总容量相同，没有额外容量收益；部分读取需经过 SSD。128 GiB SSD 最终占用 85.5%，并发生 28.417 GB eviction。因此约 15–20% 的性能下降是以 SSD 替换一半 DRAM 后的介质延迟和容量压力代价。

128D+640S：等模型成本扩容量

总容量由 256 GiB 扩大到 768 GiB。DRAM 保持 hot working set，SSD 保存更多 cold KV；SSD 最终仅占用 26.8%，淘汰显著减少。在本 workload 下，额外容量 减少了容量淘汰与重复计算，其收益超过 SSD 访问延迟。

结论边界：在成本受限条件下，较大的 DRAM+SSD 缓存容量可能优于 较小的纯 DRAM 缓存；这不表示 SSD 比 DRAM 更快。

实验限制

1. 256D 使用 75c50dc4；混合组使用 c68b4090-busyretry，尚非完全同镜像。
2. SSD 修复不进入纯 DRAM backend，但 BUSY 协议涉及共享 PoolClient/PeerPool 路径。
3. 每组目前仅一次正式运行，没有标准差与置信区间。
4. SSD 为共享系统 NVMe，并非独占 benchmark 设备。
5. UMBP metrics 缺少 resolve/miss 分母，无法报告真正 L3 hit rate。
6. DRAM:SSD=5:1 是实验模型，不是采购成本。
7. closed-loop 下各组在相同 trace 上推进距离不同，不宜直接比较累计 hit counter。

后续验证

1. 使用 3673fee7 镜像重跑 256D，消除代码镜像差异。
2. 三组按交错顺序至少重复 3 次，报告 median、标准差和 95% CI。
3. profiling 前后分别采集 UMBP counter，使用窗口 delta。
4. 增加 resolve attempts/found/missing/busy 分母，计算 object/byte hit rate。
5. 记录 SSD latency、IOPS、queue depth、bandwidth 与 staging 利用率时间序列。

当前同镜像 256D 重跑需等待 n09-25 再次获得独占资源。正式更新完成前，本报告中的 256D 仍为 75c50dc4 原始基线。